

MINERAÇÃO DE DADOS (TÓPICOS ESPECIAIS EM INTELIGÊNCIA ARTIFICIAL)

Seminário 3 — Redes Neurais Recorrentes
RNN, LSTM e GRU aplicadas na previsão e marcação a
mercado de título do Tesouro Direto

Universidade Federal do Sul e Sudeste do Pará
Instituto de Geociências e Engenharias
Faculdade de Sistemas de Informação
Prof. Adam D. F. dos Santos

1. Visão Geral

Este seminário parte de um [notebook exemplo](#) fornecido pelo professor (que cobre carregamento dos [dados](#), pré-processamento, treinamento de RNN/LSTM/GRU e marcação a mercado com quartis) e **pede que cada grupo adapte esse código para o seu título NTN-B específico durante todo o seu período de existência**, realizando experimentos próprios e interpretando os resultados à luz do contexto de renda fixa.

Parâmetro	Descrição
Tema	RNN, LSTM e GRU aplicadas na previsão e marcação a mercado de NTN-B Principal
Data e Duração	23/04/2026 — 40 min (Apresentação de duas equipes)
Grupos	9 grupos
Títulos	5 títulos NTN-B Principal (venc. 2026, 2029, 2035, 2045 e 2050)
Formato	Experimento prático com notebook Python (Google Colab ou similar)
Infraestrutura	Google Colab gratuito (CPU suficiente; GPU acelera)
Notebook base	Fornecido pelo professor — contém carregamento dos dados, RNN/LSTM/GRU e marcação a mercado
Entrega escrita	Ficha Técnica — 2 a 3 páginas (ver Seção 5)

O notebook base usa o título NTN-B Princ 150535 como demonstração (*i.e.*, título NTN-B Principal com vencimento em 2035). Os dados podem ser baixados no site: <https://www.tesourodireto.com.br/produtos/dados-sobre-titulos/historico-de-precos-e-taxas>

2. Títulos, Grupos e Linhas de Investigação

Os 9 grupos são divididos em duas linhas de investigação. Grupos da mesma linha partilham a abordagem técnica, mas cada grupo trabalha com um título diferente, garantindo diversidade. Por exemplo, G1 e G3 trabalham com o mesmo título (150535), mas em linhas opostas.

Grupo	Título NTN-B	Vencimento	Linha	Observação
G6	NTN-B Princ 150826	15/08/2026	A — Univariado	Feature: Taxa Compra Alvo: Taxa Compra
G8	NTN-B Princ 150529	15/05/2029	A — Univariado	Feature: Taxa Venda Alvo: Taxa Venda
G3	NTN-B Princ 150535	15/05/2035	A — Univariado	Feature: Taxa Compra Alvo: Taxa Compra
G9	NTN-B Princ 150545	15/05/2045	A — Univariado	Feature: Taxa Venda Alvo: Taxa Venda
G5	NTN-B Princ 150850	15/08/2050	A — Univariado	Feature: Taxa Compra Alvo: Taxa Compra
G4	NTN-B Princ 150826	15/08/2026	B — Multivariado	Features: Taxa Compra + Taxa Venda + PU Compra + PU Venda Alvo: Taxa Compra
G7	NTN-B Princ 150529	15/05/2029	B — Multivariado	Features: Taxa Compra + Taxa Venda + PU Compra + PU Venda Alvo: Taxa Compra
G2	NTN-B Princ 150545	15/05/2045	B — Multivariado	Features: Taxa Compra + Taxa Venda + PU Compra + PU Venda Alvo: Taxa Compra
G1	NTN-B Princ 150535	15/05/2035	B — Multivariado	Features: Taxa Compra + Taxa Venda + PU Compra + PU Venda Alvo: Taxa Compra

3. Parte Prática — Experimento

3.1 Linha A — Previsão Univariada

Cada grupo usa apenas a coluna de Taxa Compra Manhã ou Taxa Venda Manhã como feature de entrada. A tarefa é prever a taxa do próximo dia útil (ou do horizonte definido pelo grupo). O notebook base já implementa esse pipeline completo, o grupo precisa apenas ajustar os parâmetros do seu foco específico e realizar a marcação a mercado.

Configuração base — Linha A (alterar apenas os parâmetros do foco do grupo)			
ABA	=	'<nome da aba do seu título>'	# ajustar para o título do grupo
JANELA	=	20	# comprimento da janela de entrada (dias úteis)
HORIZONTE	=	1	# dias à frente a prever
SPLIT_TREINO	=	0.80	# divisão cronológica treino / teste
HIDDEN SIZE	=	64	# unidades ocultas de cada modelo
NUM_LAYERS	=	1	# número de camadas empilhadas
DROPOUT	=	0.0	# regularização (ativar ao usar NUM_LAYERS > 1)
EPOCHS	=	150	# épocas de treinamento
LR	=	1e-3	# taxa de aprendizado (Adam)

Etapas do experimento — Linha A:

- Ajuste do parâmetro ABA e verificação da série carregada (datas, total de dias, taxa mín./máx.).
- Execução do pipeline base: pré-processamento, treinamento dos 3 modelos, tabela de métricas.
- Experimento específico do grupo: variar o parâmetro indicado na tabela da Seção 2 e comparar os resultados.
- Comparação com o baseline Naive (prever taxa de hoje = taxa de amanhã).
- Análise visual: gráfico de previsão vs. real no período de teste; em que momentos o modelo erra mais?
- **É necessária alguma modificação na marcação a mercado para os casos em que o alvo é a taxa de venda?**

3.2 Linha B — Multivariado

Além da taxa de compra, os grupos da Linha B incorporam as colunas de Taxa Venda Manhã, PU Compra Manhã e PU Venda Manhã como features adicionais, alterando INPUT_SIZE = 4.

Configuração base — Linha B (ajustes em relação à Linha A)

```
INPUT_SIZE    = 4          # 4 features: Taxa Compra, Taxa Venda, PU Compra,
                           PU Venda
ABA           = '<nome da aba do seu título>'
JANELA_QUARTIL = 60       # janela para cálculo dos quartis (dias úteis)
# Demais parâmetros: mesmos da Linha A
```

Para carregar as 4 colunas, substituir em criar_janelas:

Adaptação da função criar_janelas para multivariado

```
# No carregamento dos dados, substituir:
df_raw = df_raw[['Dia', 'Taxa Compra Manhã', 'Taxa Venda Manhã', 'PU Compra
Manhã', 'PU Venda Manhã']]
df_raw.columns = ['Data', 'TaxaCompra', 'TaxaVenda', 'PUCompra', 'PUVenda']

# Normalizar cada coluna separadamente com o mesmo MinMaxScaler
# e empilhar como tensor de shape (n_amostras, JANELA, 4)
```

Etapas do experimento — Linha B:

- Todos os passos da Linha A (usando as 4 features).
- Comparar MSE do modelo multivariado com o univariado do mesmo título: a informação extra ajuda?
- Executar a seção de marcação a mercado: calcular Q1, Q3 e sinal de compra com janela móvel de 60 dias (pode modificar).
- Analisar a distribuição dos sinais (% de dias em Compra / Neutro / Evitar) e o ganho médio de taxa nos dias de sinal verde.
- Calcular o sinal combinado (modelo prevê taxa > Q3 E taxa atual > Q3) e comparar com o sinal de quartil isolado.

4. Roteiro do Seminário

4.1 Estrutura de Cada Apresentação — 15 a 20 minutos

Tempo	Conteúdo
[3 min]	Contexto: o que é NTN-B Principal, por que prever a taxa importa, qual título o grupo trabalhou.
[4 min]	Metodologia: pré-processamento (janela, normalização, divisão cronológica), arquiteturas usadas, hiperparâmetros testados.
[5 min]	Resultado principal: tabela de métricas (RMSE, MAE, MAPE), curvas de previsão vs. real, comparação com baseline Naive.
[3 min]	Marcação a mercado: sinal de compra, dias em cada zona, ganho médio de taxa no sinal verde.
[2 min]	Pergunta em aberto: o que o experimento não respondeu? O que melhoraria o modelo?

5. Entrega Escrita — Ficha Técnica

5.1 Especificações

Item	Especificação
Formato	PDF
Extensão	2 a 3 páginas (excluindo figuras e referências)
Prazo	24h antes do seminário via SIGAA
Obrigatório para	Todos os 9 grupos
Link do notebook	Incluir link público do Colab ao final da Ficha Técnica

5.2 Estrutura da Ficha Técnica

Seção	Conteúdo esperado	Peso
1. Identificação	Grupo, título NTN-B, linha (A ou B), link do notebook	5%
2. Dados e pré-processamento	Descrição do título, período, janela usada, normalização, divisão treino/teste — justificar cada escolha	15%
3. Modelos e experimentos	Arquiteturas testadas, hiperparâmetros variados (conforme foco do grupo), curvas de loss	20%
4. Resultados	Tabela de métricas (RMSE, MAE, MAPE) para todos os modelos + baseline Naive; gráfico de previsão vs. real obrigatório	25%
5. Marcação a mercado	Gráfico de sinal de compra/venda com bandas Q1/Q3; tabela com taxa média por regime; análise do sinal combinado (rede + quartis)	15%
6. Reflexão crítica	O que o experimento não respondeu? Que dados adicionais melhorariam o modelo? Usar previsão para decisão de investimento tem riscos? Quais?	20%

5.3 Figuras Obrigatórias

Figura obrigatória	Figura recomendada
Gráfico de previsão vs. real no período de teste (escala de taxa % a.a.)	Curvas de loss treino/validação + scatter previsto × real
Gráfico de previsão vs. real + gráfico de marcação a mercado com bandas Q1/Q3 e sinal de compra/venda	Tabela de taxa média por regime (Compra / Neutro / Evitar) + sinal combinado

6. Referências Sugeridas

6.1 Redes Neurais Recorrentes (LSTM, GRU)

- Hochreiter, S.; Schmidhuber, J.: Long Short-Term Memory. *Neural Computation*, v. 9, n. 8, p. 1735–1780, 1997. (Artigo original da LSTM)
- Cho, K. et al.: Learning Phrase Representations using RNN Encoder-Decoder for Statistical Machine Translation. *EMNLP*, 2014. (Artigo original da GRU)
- Bengio, Y.; Simard, P.; Frasconi, P.: Learning Long-Term Dependencies with Gradient Descent is Difficult. *IEEE Transactions on Neural Networks*, 1994. (Motivação para LSTM — vanishing gradient)

6.2 Previsão de Séries Temporais Financeiras

- Fischer, T.; Krauss, C.: Deep learning with long short-term memory networks for financial market predictions. *European Journal of Operational Research*, v. 270, n. 2, p. 654–669, 2018.
- Siami-Namini, S.; Tavakoli, N.; Namin, A. S.: A Comparison of ARIMA and LSTM in Forecasting Time Series. *IEEE ICDMW*, 2018. (Benchmark LSTM vs. ARIMA em séries financeiras)
- Heaton, J. B.; Polson, N. G.; Witte, J. H.: *Deep Learning for Finance: Deep Portfolios*. Applied Stochastic Models in Business and Industry, 2017.

6.3 Renda Fixa e Tesouro Direto

- Tesouro Nacional: Tesouro Direto — Informações sobre os títulos públicos. Disponível em: <https://www.tesourodireto.com.br>. (Documentação oficial dos títulos NTN-B)
- Fabozzi, F. J.: *Fixed Income Mathematics*. 4. ed. McGraw-Hill, 2006. (Referência clássica para marcação a mercado e duração de títulos indexados)
- Banco Central do Brasil: Sistema de Informações de Crédito — Séries Históricas. Disponível em: <https://www.bcb.gov.br>. (Dados históricos de taxa Selic e inflação — contexto para interpretar as taxas NTN-B)

7. Critérios de Avaliação

Componente	Descrição	Peso
Ficha Técnica	Qualidade do relatório, figuras obrigatórias, análise de resultados e reflexão crítica	35%
Apresentação oral	Clareza, síntese, ancoragem nos dados experimentais do próprio grupo	30%
Arguição cruzada	Qualidade das perguntas à outra linha e das respostas recebidas	20%
Participação no debate	Contribuições ao debate aberto com perguntas ou comentários fundamentados	15%